Hive Pig 实习报告

薛飞跃 1700017831

实验步骤

- 1. 按照指导安装 Hive Pig 并调试
- 2. 分别在 Hive 和 Pig 中导入数据,并完成相应的查询

实验过程

Hive:

1. 建表,并导入数据。

2. 查询病毒在全球、中国湖北、中国大陆其它省份的病死率。

3. 查询确诊人数超过 5000 的国家/地区中病死率前三的国家/地区。

```
0: jdbc:hive2://localhost:10000> select country,sum(deaths)/sum(confirmed) as deathrate from covid
......> group by country having sum(confirmed)>5000 order by deathrate desc limit 3;
WARNING: Hive-on-MR is deprecated in Hive 2 and may not be available in the future versions. Consider using a
.....
| country | deathrate |
| Algeria | 0.11279048656499636 |
| Italy | 0.11262467597732054 |
| San Marino | 0.101905311778291 |
```

4.查询确诊人数超过 5000 的国家/地区中治愈率前三的国家/地区。

Pig:

1. 加载数据。

grunt> covid = load '/usr/local/hive/apache-hive-2.3.6-bin/time-series-19-covid-combined_csv.csv' using PigStorage(',') as (day:chararray,country:chararray,province:chararray,lat:float,long:float, confirmed:int,recovered:int,deaths:int);

2. 查询病毒在全球的病死率。

```
temp = group covid all;
```

grunt> temp2 = foreach temp generate (float)SUM(covid.deaths)/SUM(covid.confirmed);

3. 查询病毒在中国湖北的病死率。

grunt> temp = filter covid by province == 'Hubei';

grunt'> temp2 = group temp all;

```
(all,0.0420666)
grunt> temp3 = foreach temp2 generate group,(float)SUM(temp.$7)/SUM(temp.$5);
```

4. 查询病毒在中国大陆其它省份的病死率。

```
(all,0.007507954)
grunt> temp = filter covid by country=='China' and province != 'Hubei';
temp2 和 temp3 和第 3 步相同。
```

5. 按国家分组, 计算每个国家的病死率和确诊人数, 保留确诊人数超过 5000 的国家, 按病死率降序排列, 选择前三名。

grunt> temp = group covid by country;

grunt> temp1 = foreach temp generate group,(float)SUM(covid.\$7)/SUM(covid.\$5),SUM(covid.\$5);

```
grunt> temp2 = filter temp1 by $2 >5000;
```

grunt> temp3 = order temp2 by \$1 desc;

```
(Algeria,0.11279049,22032)
(Italy,0.112624675,2817704)
grunt> temp4 = limit temp3 3;
```

6. 查询确诊人数 5000 以上的治愈率前三的国家/地区。

```
grunt> temp1 = foreach temp generate group,(float)SUM(covid.$6)/SUM(covid.$5);

(China,0.6397353,5179408)
(Bahrain,0.48623592,17582)
grunt> dump temp4;
```

心得和总结:

- 1. 互相验证, pig 和 hive 查询的结果都正确且相同。
- 2. csv 是逗号分隔符文件,而每一列存储的字符可能本身包含逗号,如果仅仅用逗号分隔来读取文件,可能会导致一些问题。
- 3. hive 直接套用 sql 的语法, piq 的语法要特别注意一些细节, 如等号前面必须有空格,

sum, count 等符号注意大小写, 建表时, Date 是数据类型的保留字符, 尽量避开用 Date 作为列名。